Методы машинного обучения

Лекция 10

Решающие деревья

Эльвира Зиннурова

elvirazinnurova@gmail.com

НИУ ВШЭ, 2019

Параметры и гиперпараметры

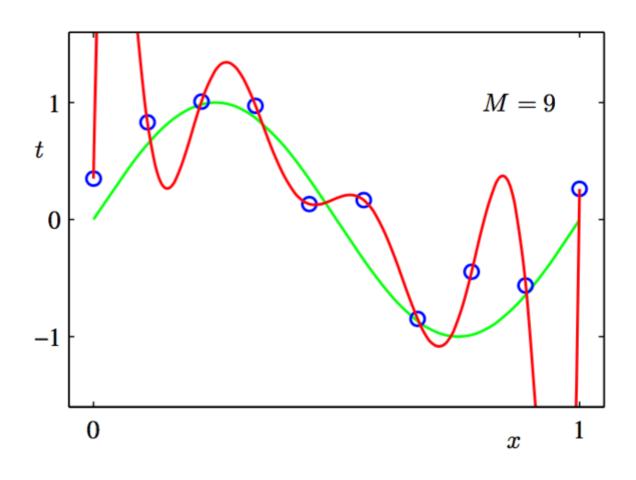
Простой пример

- Максимизируем удовлетворённость студентов
- Обучающая выборка время до сессии
- Контрольная выборка сессия
- Параметр продолжительность лекции
- Гиперпараметр минимальная продолжительность лекции

Простой пример

- Максимизируем удовлетворённость студентов
- Обучающая выборка время до сессии
- Контрольная выборка сессия
- Параметр продолжительность лекции
- Гиперпараметр минимальная продолжительность лекции
- Максимальная удовлетворённость на обучении если не ограничивать продолжительность
- Но оценки во время сессии будут ужасными

Переобучение

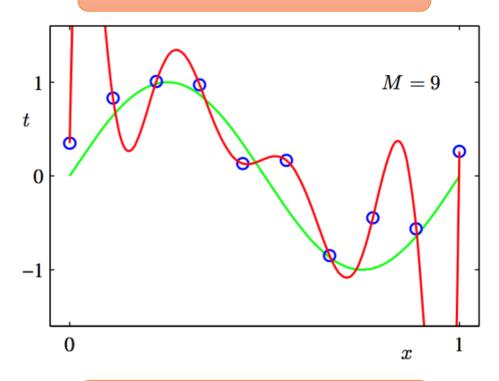


Регуляризация

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (\langle w, x_i \rangle - y_i)^2 + \lambda ||w||^2 \to \min_{w}$$

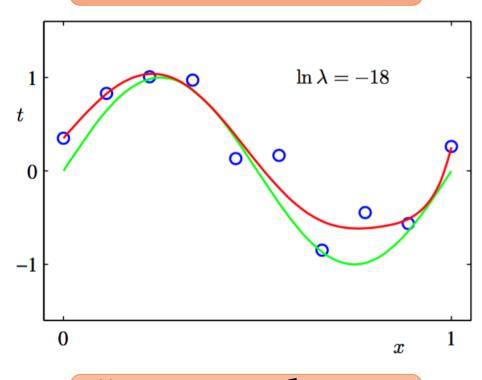
- Параметры модели веса w
 - Позволяют подогнать модель под обучающую выборку
 - Настраиваются по обучающей выборке
- Гиперпараметр модели коэффициент регуляризации λ
 - Определяют сложность модели
 - Лучшее качество на обучении достигается при $\lambda=0$
 - Необходимо настраивать по другим данным отложенная выборка, кросс-валидация и т.п.

Без регуляризации



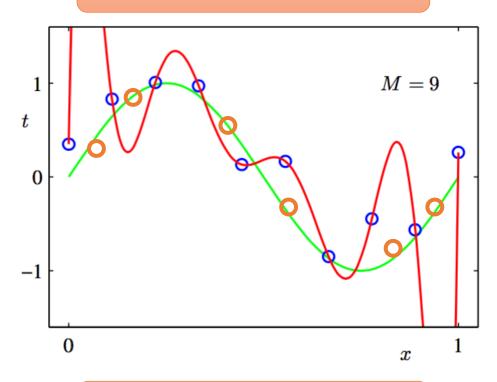
Высокое качество на обучении

С регуляризацией



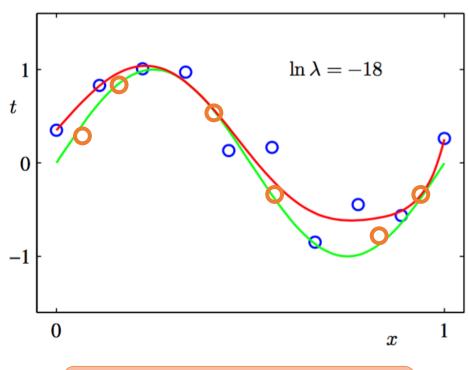
Качество на обучении ниже

Без регуляризации



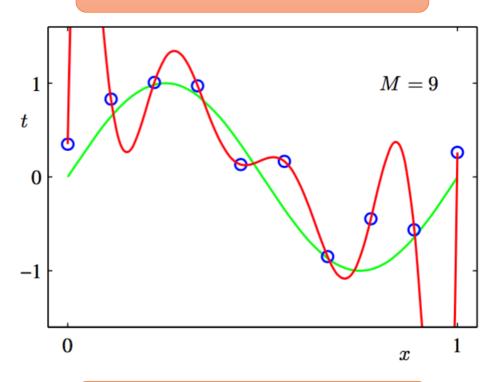
Низкое качество на тесте

С регуляризацией



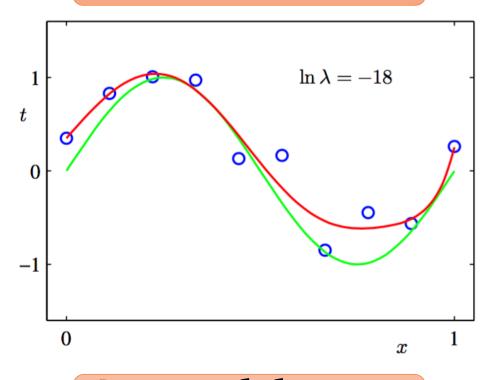
Высокое качество на тесте

Без регуляризации



Низкая обобщающая способность

С регуляризацией

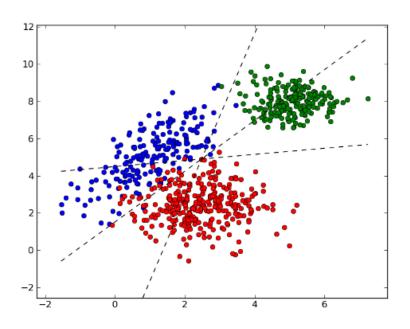


Высокая обобщающая способность

Многоклассовые задачи

Многоклассовая классификация

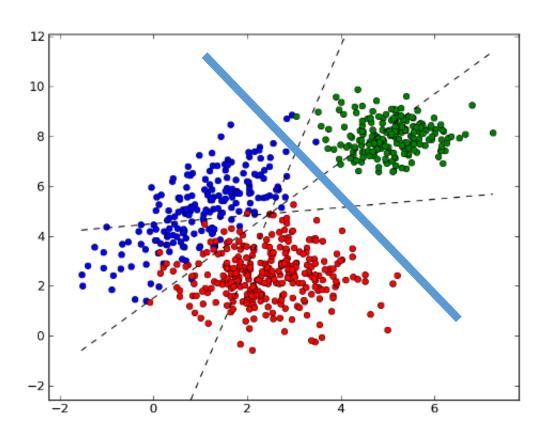
• $\mathbb{Y} = \{1, 2, ..., K\}$

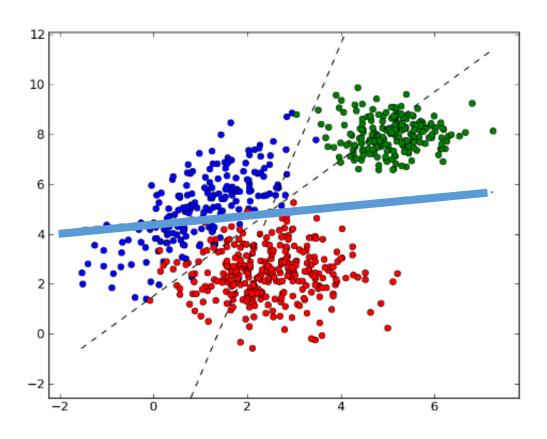


Бинарная классификация

$$a(x) = \operatorname{sign} \langle w, x \rangle$$

- Способ сведения многоклассовой задачи к набору бинарных классификаций
- Обучаем свой классификатор для каждого класса
- Задача: отделение класса от всех остальных





- К задач бинарной классификации
- *k*-я задача:
 - $X = (x_i, [y_i = k])_{i=1}^{\ell}$
 - Классификатор $a_k(x) = \text{sign } \langle w_k, x \rangle$
- Алгоритм:

$$a(x) = \arg \max_{k \in \{1, \dots, K\}} \langle w_k, x \rangle$$

Матрица ошибок

	y = 1	y = 2		y = K
a(x) = 1	q_{11}	q_{12}	•••	q_{1K}
a(x) = 2	q_{21}	q_{22}	•••	q_{2K}
•••	•••	•••	•••	•••
a(x) = K	q_{K1}	q_{K2}	•••	q_{KK}

Доля правильных ответов

$$accuracy(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) = y_i]$$

Точность и полнота

- Относительно каждого класса
- Можно усреднить точность и полноту по всем классам
- Можно усреднить F-меру